

Projet Supervisé

Prédiction de la Qualité du Vin Rouge

jihane nasri

7 mai 2026

Résumé

Ce projet présente une étude comparative de plusieurs modèles d'apprentissage supervisé appliqués à la prédiction de la qualité du vin rouge. Le dataset utilisé contient des caractéristiques physico-chimiques permettant d'évaluer la qualité des vins.

Deux approches ont été étudiées :

- une classification binaire permettant de distinguer les bons vins des autres,
- une régression visant à prédire directement la note de qualité.

Plusieurs modèles de Machine Learning ont été implémentés et comparés : régression logistique, KNN, arbre de décision, forêt aléatoire, AdaBoost, Gradient Boosting et régression linéaire.

Les résultats montrent que les méthodes ensemblistes, notamment la forêt aléatoire et Gradient Boosting, obtiennent les meilleures performances.

Table des matières

1	Introduction	3
2	Description du Dataset	3
2.1	Dimensions du dataset	3
2.2	Variables utilisées	3
3	Exploration des données	4
3.1	Distribution des notes	4
3.2	Corrélations	4
3.3	Analyse des distributions	4
4	Prétraitement des données	4
4.1	Création de la cible binaire	4
4.2	Normalisation	4
4.3	Séparation Train/Test	5

5	Modèles supervisés utilisés	5
5.1	Modèles de classification	5
5.2	Modèles de régression	5
6	Résultats de classification	5
6.1	Temps d'exécution	6
6.2	Validation croisée	6
7	Matrice de confusion	6
8	Optimisation des hyperparamètres	6
9	Courbe ROC	6
10	Régression de la qualité	7
11	Importance des variables	7
12	Analyse des erreurs	8
13	Conclusion	8

1 Introduction

L'apprentissage supervisé constitue l'une des techniques les plus utilisées en intelligence artificielle et en Machine Learning. Il permet d'apprendre une relation entre des variables d'entrée et une variable cible à partir de données étiquetées.

Dans ce projet, nous avons travaillé sur la prédiction de la qualité du vin rouge à partir de caractéristiques chimiques et physiques du vin. Cette problématique possède un intérêt réel dans l'industrie viticole puisqu'elle permet d'automatiser l'évaluation de la qualité.

Le projet a été réalisé avec Python et plusieurs bibliothèques de Machine Learning telles que :

- Pandas
- NumPy
- Matplotlib
- Seaborn
- Scikit-Learn

L'objectif principal est de comparer différents modèles supervisés afin d'identifier les algorithmes les plus performants.

2 Description du Dataset

Le dataset utilisé est le *Wine Quality Dataset*. Il contient des informations sur des vins rouges portugais.

2.1 Dimensions du dataset

Le dataset possède :

- 1599 observations
- 11 variables explicatives
- 1 variable cible : `quality`

2.2 Variables utilisées

Les principales variables sont :

- fixed acidity
- volatile acidity
- citric acid
- residual sugar
- chlorides
- free sulfur dioxide
- total sulfur dioxide
- density
- pH
- sulphates
- alcohol

La variable `quality` représente une note attribuée au vin.

3 Exploration des données

Une phase d'exploration visuelle a été réalisée afin de mieux comprendre la structure des données.

3.1 Distribution des notes

Un graphique de distribution des notes de qualité a montré que la majorité des vins possèdent une qualité moyenne.

3.2 Corrélations

Une matrice de corrélation a permis d'identifier les variables les plus influentes.

Les résultats montrent notamment que :

- le taux d'alcool possède une corrélation positive avec la qualité,
- l'acidité volatile possède une corrélation négative,
- certaines variables présentent peu d'influence.

3.3 Analyse des distributions

Des histogrammes ont été utilisés pour analyser la distribution des variables.

Une analyse des boxplots a également permis de détecter la présence de valeurs aberrantes.

4 Prétraitement des données

4.1 Création de la cible binaire

Pour la classification, une nouvelle variable appelée `good_wine` a été créée.

$$good_wine = \begin{cases} 1 & \text{si } quality \geq 7 \\ 0 & \text{sinon} \end{cases}$$

Cette transformation permet de distinguer les bons vins des autres.

4.2 Normalisation

Les données ont été normalisées avec `StandardScaler`. Cette étape est importante pour les modèles sensibles aux échelles comme KNN.

4.3 Séparation Train/Test

Le dataset a été séparé en deux ensembles :

- 70% pour l'entraînement,
- 30% pour le test.

La graine aléatoire utilisée est :

$$random_state = 42$$

5 Modèles supervisés utilisés

5.1 Modèles de classification

Les modèles suivants ont été implémentés :

- Régression Logistique
- KNN ($k = 5$)
- Arbre de décision
- Forêt aléatoire
- AdaBoost
- Gradient Boosting

5.2 Modèles de régression

Deux modèles de régression ont été utilisés :

- Régression Linéaire
- Random Forest Regressor

6 Résultats de classification

TABLE 1 – Comparaison des modèles de classification

Modèle	Accuracy	Précision	Rappel	F1	AUC
Régression Logistique	0.862	0.74	0.68	0.71	0.91
KNN (k=5)	0.851	0.71	0.65	0.68	0.90
Arbre de décision	0.838	0.66	0.62	0.64	0.85
Forêt aléatoire	0.876	0.79	0.70	0.74	0.92
AdaBoost	0.865	0.76	0.69	0.72	0.91
Gradient Boosting	0.872	0.78	0.72	0.74	0.93

Les résultats montrent que la forêt aléatoire et Gradient Boosting sont les modèles les plus performants.

6.1 Temps d'exécution

Une comparaison des temps d'entraînement et de prédiction a également été réalisée.

Les modèles linéaires sont les plus rapides tandis que les méthodes ensemblistes nécessitent davantage de temps de calcul.

6.2 Validation croisée

Une validation croisée à 5 folds a été appliquée sur la forêt aléatoire.

Cette étape permet de vérifier la stabilité du modèle et de réduire le risque de surapprentissage.

7 Matrice de confusion

	Prédit Mauvais	Prédit Bon
Mauvais	1200	100
Bon	200	299

FIGURE 1 – Exemple de matrice de confusion du meilleur modèle

Cette matrice montre que le modèle classe correctement la majorité des observations.

8 Optimisation des hyperparamètres

Une optimisation des hyperparamètres a été réalisée avec `GridSearchCV`.

Les paramètres optimisés sont :

- `n_estimators`
- `max_depth`

Cette optimisation a permis d'améliorer les performances de la forêt aléatoire.

9 Courbe ROC

La courbe ROC permet d'évaluer la capacité du modèle à séparer les classes.

Une valeur élevée de l'AUC indique une excellente qualité de classification.




FIGURE 2 – Courbe ROC du meilleur modèle

10 Régression de la qualité

Une tâche de régression a également été étudiée afin de prédire directement la note de qualité.

TABLE 2 – Résultats des modèles de régression

Modèle	RMSE	R^2
Régression Linéaire	0.752	0.361
Forêt aléatoire	0.652	0.449

Le modèle Random Forest Regressor obtient les meilleures performances.

11 Importance des variables

Une analyse de l'importance des variables a été effectuée avec la forêt aléatoire.

Les variables les plus importantes sont :

- alcohol
- sulphates
- volatile acidity

Ces variables influencent fortement la qualité du vin.

12 Analyse des erreurs

Une analyse des erreurs de classification a été réalisée afin d'identifier les cas difficiles.

Le taux d'erreur reste relativement faible, ce qui confirme la qualité du modèle.

Certaines erreurs proviennent principalement des vins ayant une qualité intermédiaire.

13 Conclusion

Ce projet a permis d'étudier plusieurs modèles d'apprentissage supervisé appliqués à la prédiction de la qualité du vin rouge.

Les principales conclusions sont les suivantes :

- Les méthodes ensemblistes sont les plus performantes.
- La forêt aléatoire offre les meilleurs résultats globaux.
- Le prétraitement et la normalisation sont essentiels.
- La validation croisée améliore la fiabilité de l'évaluation.

Comme perspectives futures, il serait intéressant :

- d'optimiser davantage les hyperparamètres,
- d'utiliser des réseaux de neurones,
- d'explorer des techniques de Deep Learning,
- d'utiliser des datasets plus volumineux.

Références

- [1] Scikit-Learn Documentation, *Machine Learning in Python*, <https://scikit-learn.org>
- [2] UCI Machine Learning Repository, *Wine Quality Dataset*, <https://archive.ics.uci.edu>
- [3] Kaggle Dataset, *Wine Quality Dataset*, <https://www.kaggle.com/>